Evaluasi Akhir Semester
Semester Genap 2025/2026
Program Sarjana - Departemen Sistem Informasi
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember
Kampus ITS Sukolilo, Surabaya 60111. 031 – 5999944

Nama Anggota Kelompok:
1. Annisa Nur Fauzi 5026231228
2. Bara Ardiwinata 5026231232

NusantaraGraph: Platform Data Engineering Hibrida Dua Fase Berbasis Model Context Protocol (MCP) Server untuk Pengayaan dan Analisis Jaringan Silsilah Kerajaan Prekolonial

1. Dokumentasi Kode dan Penjelasan Logika Sistem

1.1. Latar Belakang

Sistem ini dirancang untuk mengatasi masalah pada pencatatan sejarah digital prekolonial di open-knowledge base global (Wikidata/DBpedia), berdasarkan temuan pada penelitian dan analisis sebelumnya. Kami menyimpulkan 5 *Compounding Failures,* diantaranya:

1. Relational Sparsity
   Ketiadaan atribut silsilah (ayah, ibu, pasangan) pada tokoh regional.
2. Cross-Source Entity Duplication
   Tokoh sama tercatat dengan nama berbeda (Sri Rajasanagara vs Hayam Wuruk) yang memicu phantom nodes.
3. Encoding Corruption
   Kerusakan string teks akibat double-encoding (seperti Ã…Å¡akti).
4. Jaccard Metric Distortion
   Kegagalan metrik Jaccard lama yang memicu anomali kemiripan 100% secara semu pada simpul graf yang sepi tetangga.
5. Static Retrieval Ceiling
   Limitasi RAG konvensional berbasis teks statis yang tidak bisa melakukan graph traversal secara dinamis untuk kueri multi-hop.

1.2. Arsitektur Sistem Hibrida Dua Fase

Proyek ini mengimplementasikan dua fase utama:

- Phase 1 (Data Enrichment Pipeline)
  Bertugas melakukan ekstraksi terindeks dari SPARQL, penyembuhan karakter teks, resolusi entitas, imputasi AI dari Wikipedia, serta kalkulasi metrik analitik global menggunakan NetworkX (PageRank, Louvain Modularity, Betweenness Centrality, Adamic-Adar Link Prediction).

- Phase 2 (Agentic MCP Server Layer)
  Mentransformasikan sistem interaksi menjadi Agentic AI menggunakan protokol terstandardisasi Anthropic/Model Context Protocol (FastMCP) untuk mengekspos database Neo4j menjadi sekumpulan perkakas (6 live tools suite) yang dipanggil secara dinamis oleh LLM Agent.

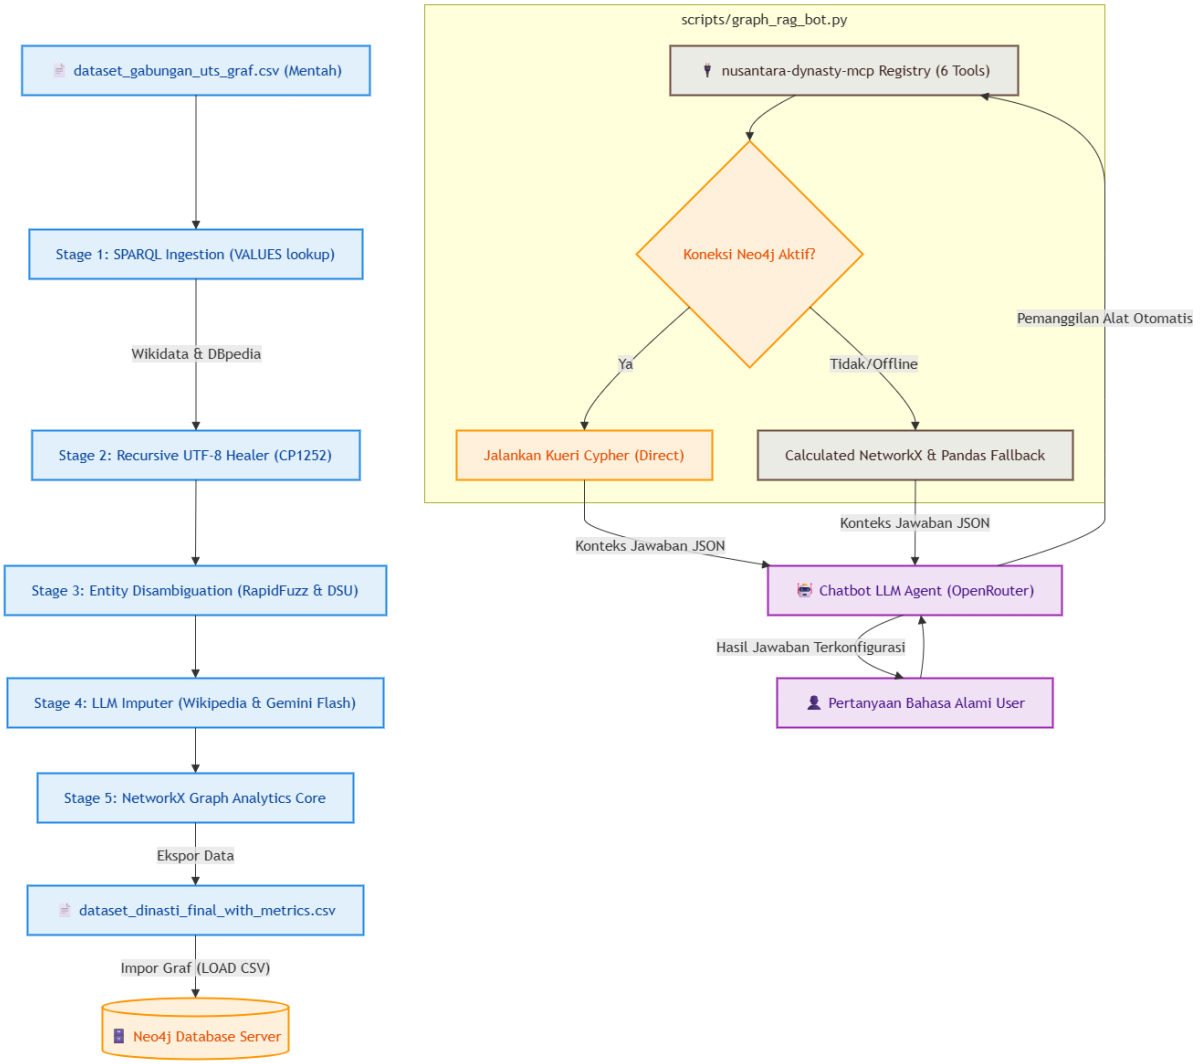


Diagram Alur Kerja Proyek

1.3. Instalasi, Konfigurasi, & Cara Menjalankan Sistem

- Prasyarat**:** Python 3.12.x atau lebih tinggi, serta Neo4j Desktop atau akses ke instance Neo4j AuraDB.
- Instalasi dependensi:
  ```
  pip install pandas requests wikipedia-api python-dotenv networkx mcp rapidfuzz
  ```
- Konfigurasi environment: buat berkas .env pada root direktori proyek berisi API key OpenRouter dan kredensial koneksi Neo4j (URI, username, password).
- Urutan eksekusi:
  1. Pipeline pengayaan data (SPARQL + Disambiguasi + LLM Imputer)

`python scripts/pipeline_graf.py`

2. Kalkulasi metrik graf (PageRank, Louvain, Betweenness, Adamic-Adar)
   `python scripts/analisis_graf.py`
3. Chatbot GraphRAG CLI (Hybrid Routing)
   `python scripts/graph_rag_bot.py`
4. Klien Agen MCP interaktif
   `python mcp_agent.py`

- Dataset hasil pengayaan diimpor ke Neo4j melalui `database/neo4j_load_queries.cypher`

1.4. Penjelasan Logika Pipeline AI & Komponen Kode

Dieksekusi melalui skrip scripts/pipeline_graf.py dan scripts/analisis_graf.py:

- Stage 1 - SPARQL Indexed Fetch
  Menggunakan operator VALUES untuk melakukan pencarian berindeks banyak tokoh sekaligus guna memangkas waktu kueri menjadi ~11 detik, menangkap variasi ejaan dan tokoh tanpa relasi SPARQL.
- Stage 2 - Recursive Encoding Healer
  Korektor rekursif biner cp1252 hingga 3 tingkat kedalaman murni UTF-8.
- Stage 3 - Entity Disambiguation (Pembaruan)
  Menjalankan fuzz.token_sort_ratio dari RapidFuzz dengan skema Kingdom-based Boosting (bonus skor +5.0 jika berafiliasi dengan kerajaan yang sama). Skor ≥ 90% langsung dipetakan, sementara skor 75%-90% divalidasi LLM OpenRouter dan dikelompokkan memakai struktur data Union-Find (Disjoint Set Union) untuk menghasilkan kolom master_id yang bersih, serta flag pelacak manual_check.
- Stage 4 - LLM Imputer
  Mengambil ringkasan teks Wikipedia API untuk tokoh yang kosong, diekstraksi oleh Gemini Flash menjadi JSON terstruktur lengkap dengan metadata confidence_score dan data_source.
- Stage 5 - Graph Analytics Engine
  Membuang total metrik Jaccard dasar. Memanfaatkan NetworkX untuk membentuk graf global (G_undir), menghitung PageRank Centrality (pengaruh tokoh), Louvain Modularity (komunitas dinasti), serta Betweenness Centrality (tokoh/kerajaan sebagai jembatan pernikahan politik/diplomatik), dan Adamic-Adar Link Prediction Index untuk kedekatan proksimitas struktural tanpa anomali pembagian kosong.

1.5. Penjelasan Logika Cypher & MCP Tools Registry

Dieksekusi melalui server asinkron `mcp_server.py` dan klien `mcp_agent.py` dengan backend logika `scripts/graph_rag_bot.py`. Server mendaftarkan 6 live tools berbasis Cypher murni ke LLM Agent:

1. `lookup_figure(name)`

- Deskripsi: Mencari properti simpul (peran, dinasti, masa hidup) dan relasi silsilah langsung dari tokoh sejarah.
- Implementasi: Query langsung Neo4j atau fallback CSV untuk menampilkan detail tokoh beserta relasi orang tua, pasangan, dan anak.

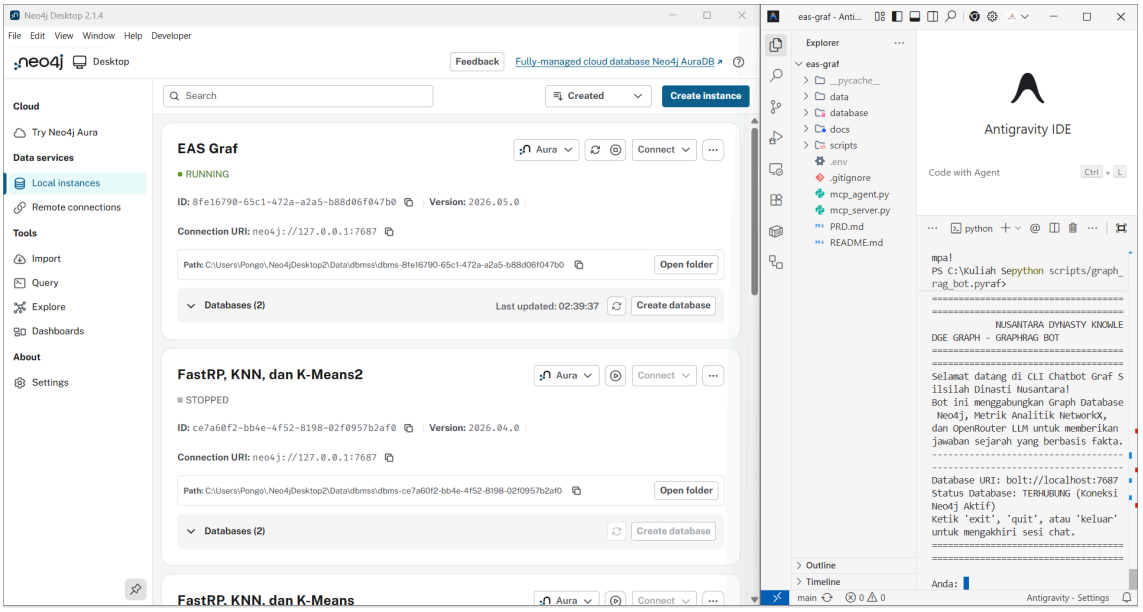
2. `get_genealogy(name, depth)`
   - Deskripsi: Melacak silsilah keturunan dan kerabat tokoh menggunakan traversal BFS (Breadth-First Search).
   - Parameter:
     i. `name` (string, required): Nama tokoh awal
     ii. `depth` (integer, optional): Kedalaman traversal (default: 2)
   - Implementasi: Graph traversal untuk mengeksplorasi multi-generasi keluarga.
3. `find_connection_path(a, b)`
   - Deskripsi: Mencari jalur hubungan silsilah terpendek (shortest path) antara dua tokoh sejarah.
   - Parameter:
     i. `a` (string, required): Tokoh pertama
     ii. `b` (string, required): Tokoh kedua
   - Implementasi: Cypher `shortestPath()` atau NetworkX `shortest_path_length()` untuk mendeteksi rute koneksi keluarga terdekat.
4. `get_influential(kingdom)`
   - Deskripsi: Mengembalikan daftar tokoh paling berpengaruh di kerajaan tertentu berdasarkan nilai PageRank tertinggi.
   - Parameter: `kingdom` (string, required): Nama kerajaan
   - Implementasi: Filter tokoh per kingdom, sortir descending berdasarkan skor PageRank yang telah dipre-compute di Stage 5 pipeline.
5. `get_community(cluster_id)`
   - Deskripsi: Menarik daftar tokoh sejarah yang tergabung dalam kelompok klaster dinasti yang sama berdasarkan ID Klaster Louvain.
   - Parameter: `cluster_id` (integer, required): ID Klaster Louvain
   - Implementasi: Kueri kolom `community_louvain` di dataset untuk mengidentifikasi anggota komunitas yang berafiliasi.
6. find_similar(name, n)
   - Deskripsi: Menghitung skor indeks kedekatan Adamic-Adar secara live untuk merekomendasikan tokoh sejarah dengan kedekatan graf silsilah tertinggi.
   - Parameter:
     i. `name` (string, required): Nama tokoh awal
     ii. `n` (integer, optional): Jumlah rekomendasi (default: 5)
   - Implementasi: NetworkX `adamic_adar_index()` tanpa anomali pembagian kosong, menghitung skor proksimitas struktural graf.

Mekanisme Dynamic Tool-Calling & Self-Healing Fallback

- Dynamic Tool Routing: LLM Agent menganalisis pertanyaan user dalam bahasa alami, memetakan parameter kueri secara dinamis, dan mengeksekusi tool yang sesuai.
- Self-Healing Fallback Engine: Jika Neo4j aktif, tools mengeksekusi Cypher secara transaksional. Jika offline, sistem otomatis mengaktifkan modul fallback lokal yang membaca dataset CSV, menyusun graf NetworkX in-memory, dan menghitung hasil analitik secara dinamis.

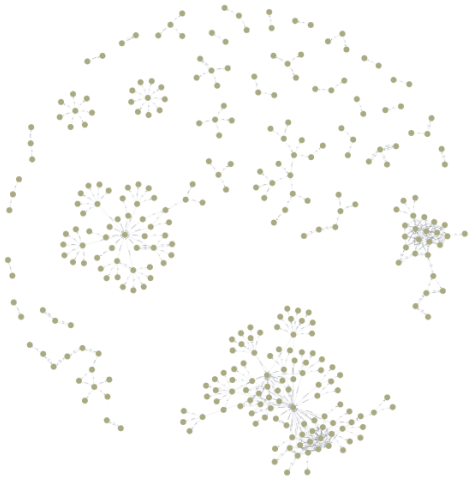
2. Screenshot Hasil Eksekusi Sistem

2.1. Bukti Koneksi Database Neo4j Aktif



Menunjukkan status database Neo4j berjalan aktif pada port default Bolt (bolt://localhost:7687) dan berhasil diverifikasi terhubung secara sukses saat inisialisasi awal.

2.2. Bukti Hasil Query / Graph Builder



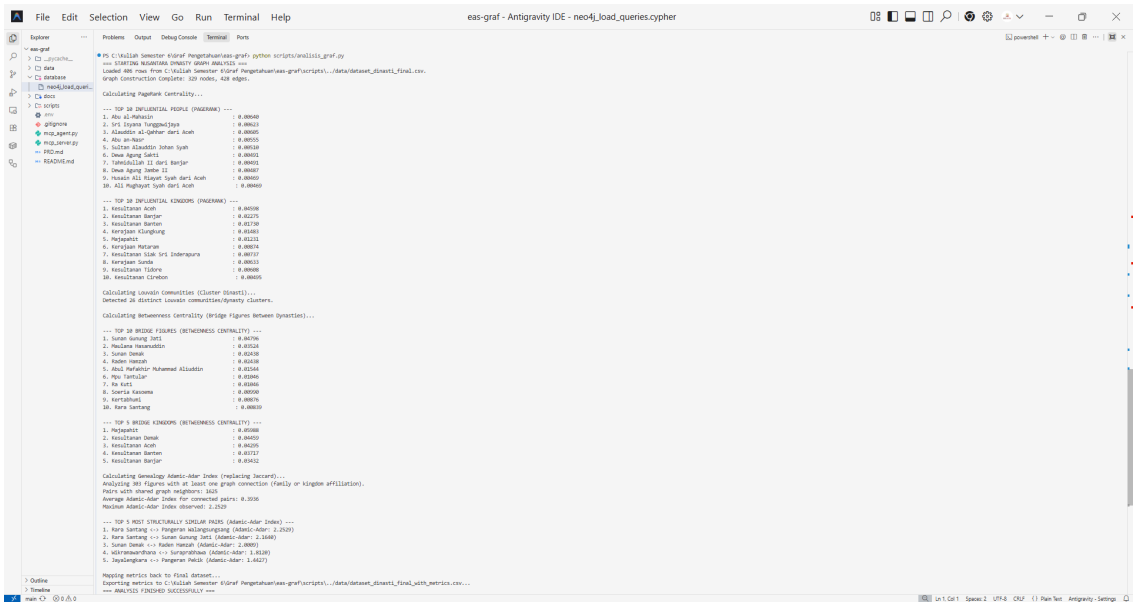
```
1 MATCH (p:Person)
2 RETURN count(p) AS TotalPersonS
```

Table RAW

TotalPerson
354

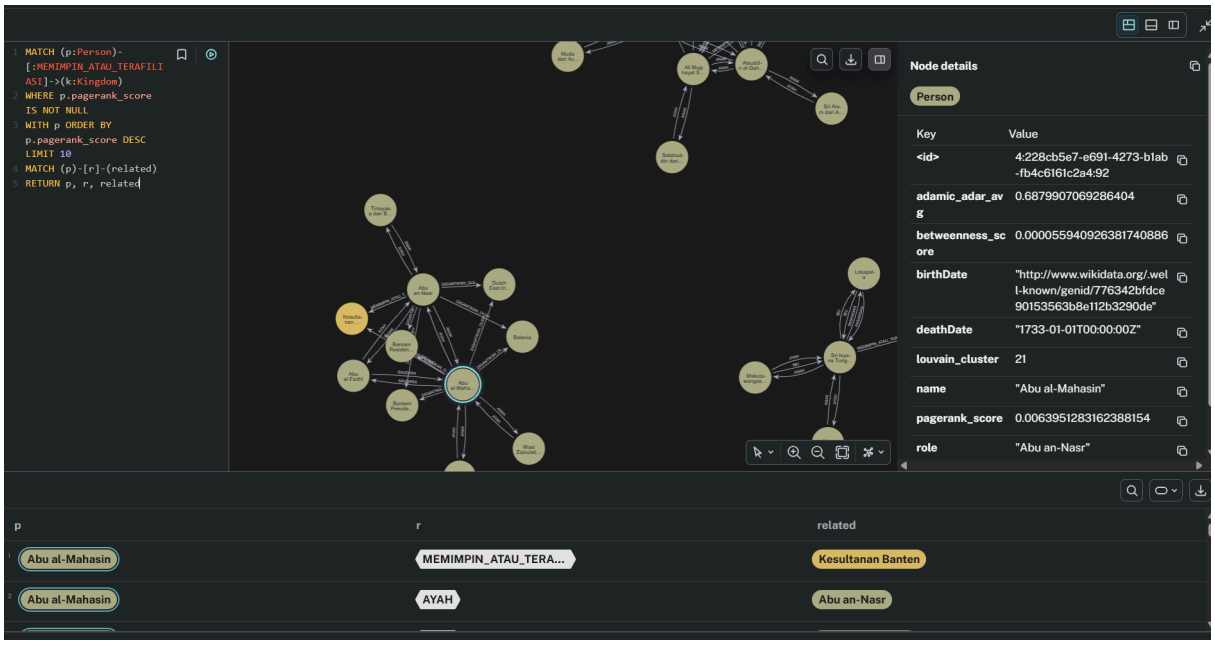
Tampilan visualisasi topologi jaringan graf silsilah hubungan keluarga penguasa prekolonial di Neo4j Browser setelah dieksekusi menggunakan perintah LOAD CSV WITH HEADERS dari file database/neo4j_load_queries.cypher. Jumlah tokoh terdeteksi adalah 354 tokoh.

2.3. Bukti Output Analisis / Metrik Jaringan Core

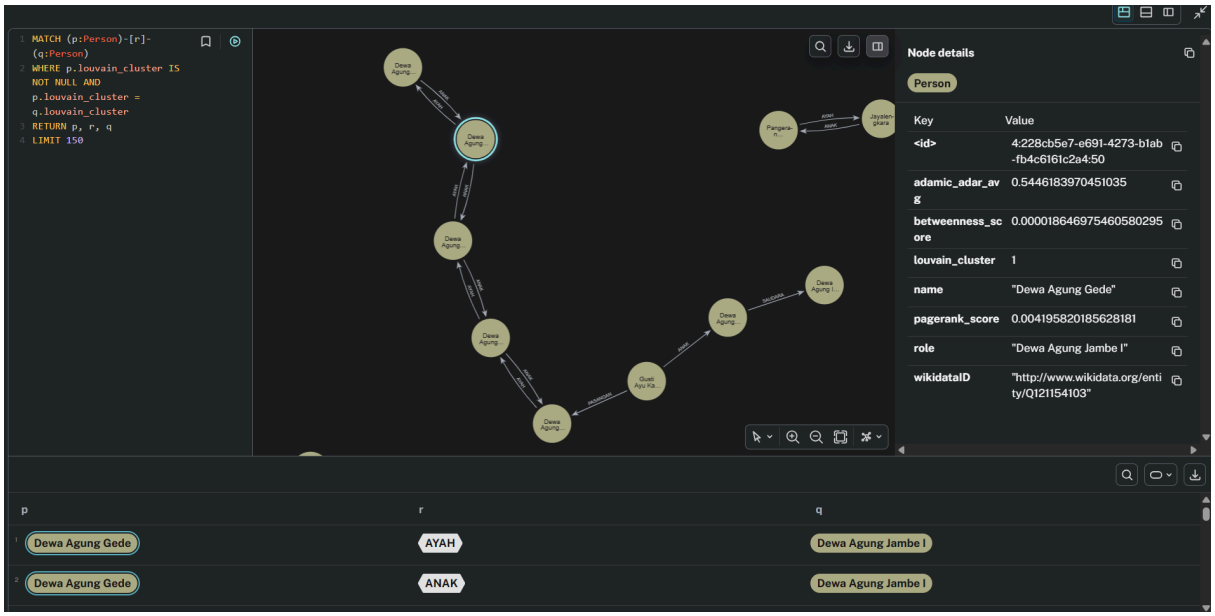


Dokumentasi log eksekusi terminal yang memperlihatkan keberhasilan penghitungan metrik analitik canggih (PageRank, Louvain Cluster ID, Betweenness Centrality, dan top 5 skor proksimitas Adamic-Adar Index seperti pasangan Dewa Agung Jambe I dengan skor 1.4427).

2.4. Visualisasi Graph di Neo4j

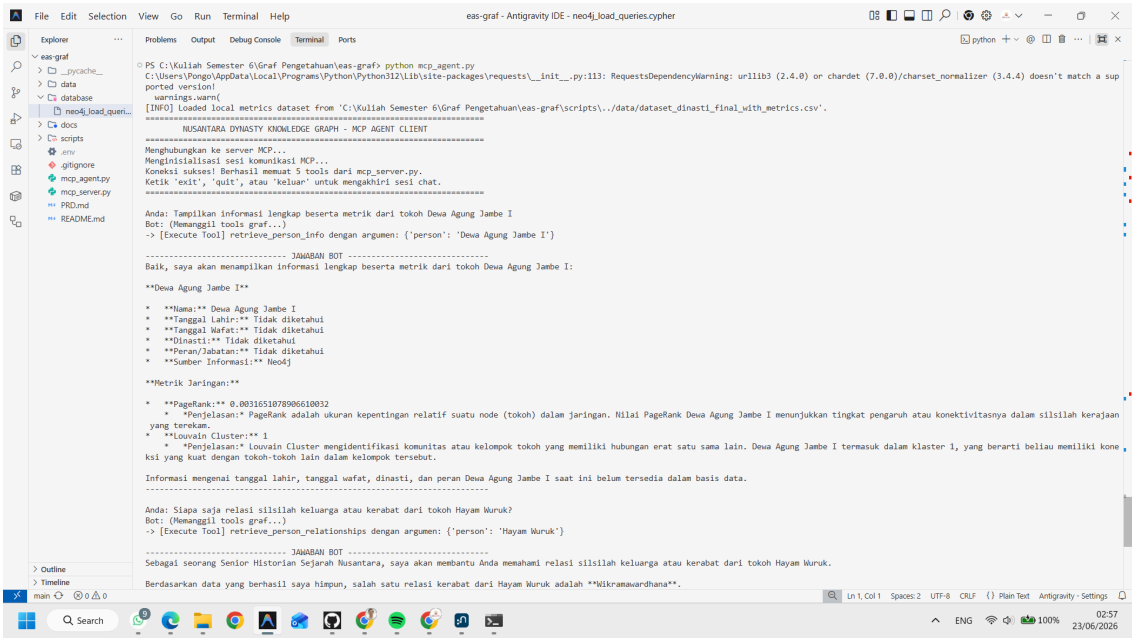


Metrik PageRank dengan tokoh berpengaruh adalah Abu Al Mahasin, Sultan dari Banten



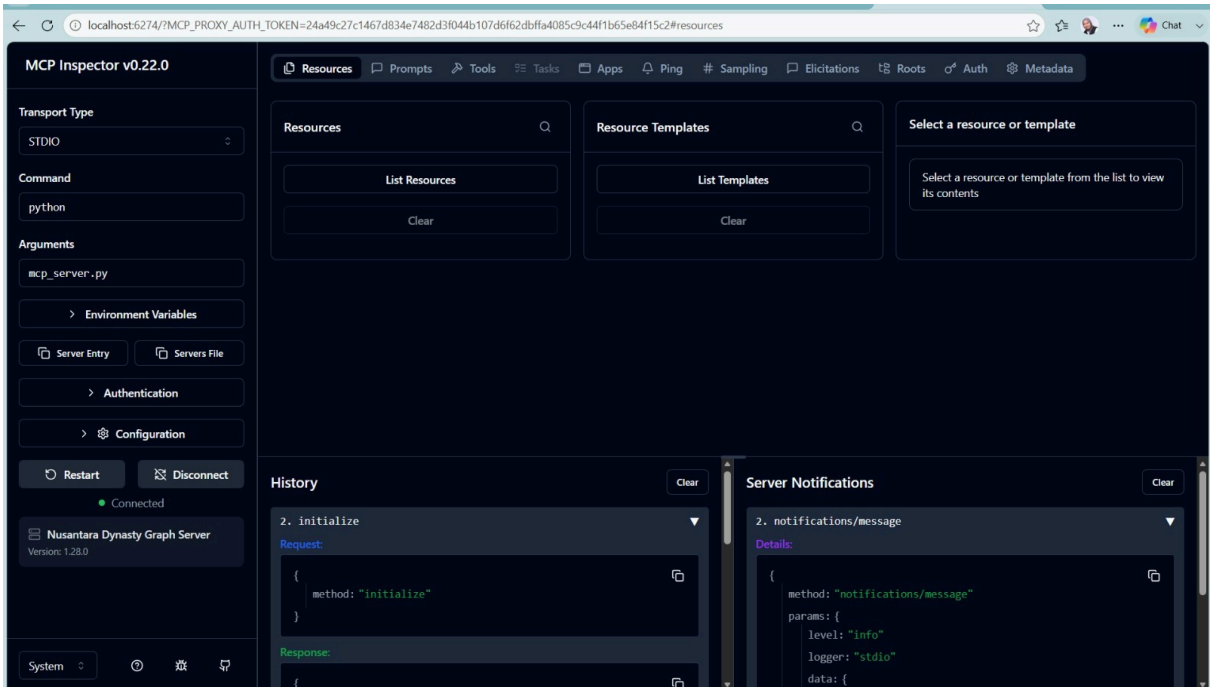
Metrik Louvain memetakan Dinasti di Bali

2.5. Bukti Demo Live Tool Call MCP Chatbot



Dokumentasi interaksi CLI Chatbot di mana pengguna memasukkan kueri bahasa alami, dan LLM Agent secara dinamis memicu log pemanggilan alat (tool calling indicator) menuju server MCP untuk mengeksekusi kueri transaksional graf secara live.

2.6. MCP Server berhasil terhubung



Server terhubung dan bisa digunakan sebagai AI Agent

3. Kesimpulan

Ringkasan Fitur & Kapabilitas Utama

- LLM untuk Text-to-Cypher: Chatbot pada graph_rag_bot.py mendeteksi pertanyaan agregasi global secara dinamis dan meluncurkan modul penerjemah *Text-to-Cypher* otomatis untuk menarik data agregat langsung dari Neo4j.
- LLM for Graph Builder: Pipeline pengayaan data pipeline_graf.py memanfaatkan Gemini Flash API untuk mengekstrak entitas keluarga baru secara terstruktur dari Wikipedia guna membangun relasi graf yang komprehensif.
- Integrasi Model Context Protocol (MCP): Logika chatbot dikendalikan sepenuhnya oleh MCPToolRegistry modular yang mengekspos sistem ke dalam *live tools* untuk navigasi, analisis, dan *traversal* graf secara *real-time* oleh LLM Agent.

Dengan mendigitalkan pembersihan data dan menyuntikkan fallback berbasis kecerdasan buatan, proyek ini memberikan peningkatan kualitas data yang terukur:

Metrik Evaluasi Grafik	Versi Awal / Eksperimen ETS	Optimalisasi Akhir Pipeline Graf	Peningkatan Kualitas & Hasil
Kecepatan Kueri SPARQL	Timeout (>60 detik) / Error 502	Combined Name & Kingdom-based UNION Lookup	Selesai dalam ~11 detik (Menangkap tokoh tanpa relasi & variasi ejaan)
Data Berhasil Ditambal AI	0 baris (Sparsity Tinggi)	Fallback Wikipedia + OpenRouter LLM	95 dari 108 tokoh berhasil ditambal (88%)
Metrik Proksimitas Kesamaan	Jaccard Similarity (Distorsi & Anomali 100%)	Adamic-Adar Link Prediction Index	Reduksi Anomali, rata-rata sehat pada skor kedekatan jaringan
Integritas Karakter Nama	Rusak (Dewa Agung Ã…Å¡akti)	Recursive Encoding Corrector (CP1252)	Normalisasi Mutlak (Dewa Agung Śakti)

4. Lampiran

Lampiran A: URL Repository GitHub Terbuka

Seluruh kode program terstruktur, modul caching, kueri perekaman Cypher, dokumentasi lengkap, serta dataset hasil pengayaan telah dipublikasikan dan dapat diakses secara publik pada tautan repositori GitHub berikut:

- URL Repository: https://github.com/BaraArdiwinata/eas-graf.git
- (Catatan: Repositori telah dikonfigurasi dengan berkas .gitignore yang tepat untuk mengecualikan pelacakan file rahasia .env berisi API Key).

Lampiran B: URL Video Demonstrasi Teknis YouTube

Video demonstrasi teknis berdurasi maksimal 5 menit yang mencakup pemaparan latar belakang masalah (5 compounding failures), demo eksekusi 5 tahap pipeline ingestion, visualisasi database Neo4j, serta simulasi Agentic tool call pada MCP Chatbot dapat diakses melalui tautan YouTube berikut:

- URL Video YouTube: https://www.youtube.com/watch?v=KWvkYyfCBUk

Lampiran C: Log Transparansi Penggunaan AI

Sesuai dengan regulasi kejujuran akademik, berikut adalah catatan transparansi pemanfaatan teknologi AI:

- Model AI Pendukung
  Antigravity IDE (Gemini 3.5 Flash) dan Claude AI.
- Porsi Otomatisasi AI
  Membantu rancangan modularisasi folder direktori, struktur algoritma pencocokan kemiripan kata kunci string RapidFuzz, pemanfaatan struktur data Union-Find (Disjoint Set Union), serta skema registrasi kelas FastMCP Anthropic.
- Kontribusi Manual Anggota Kelompok
  Penyelarasan jalur pemanggilan berkas (dynamic relative file pathing) lintas folder, penulisan kueri seleksi properti Cypher secara spesifik di file .cypher, serta modifikasi perancangan logika in-memory networkx pada mekanisme self-healing fallback engine saat database offline.